Documentación Técnica: Database y Justificación de Normalización

Equipo 1 Computación II

Diccionario y Estructura del Database

Este documento detalla la composición de la base de datos de boxscores de la NBA (2013-2023), desglosando cada entidad y sus respectivos atributos según el esquema SQL proporcionado. Sirve como la fuente principal para identificar el contexto, el rendimiento y el resultado final de cada encuentro.

---

1. Entidad: game_info

Esta tabla contiene los metadatos generales de cada partido. Es fundamental para establecer el marco temporal y geográfico de los eventos.

game_id: Identificador único numérico para cada partido. Es la clave primaria indispensable para relacionar esta tabla con las estadísticas detalladas de jugadores y equipos.

season: El año de la temporada regular. Por ejemplo, se registra como 2014 para referirse a la temporada completa 2013-14.

date: La fecha calendario exacta en la que se disputó el partido, almacenada originalmente como cadena de texto.

away_team: Nombre completo o abreviatura oficial del equipo que juega en calidad de visitante.

home_team: Nombre completo o abreviatura oficial del equipo que juega en calidad de local.

away_score: Cantidad total de puntos anotados por el equipo visitante al sonar la bocina final.

home_score: Cantidad total de puntos anotados por el equipo local al sonar la bocina final.

result: Indicador binario que resume el resultado del partido. Generalmente, un valor de 1 indica la victoria del equipo local y un valor de 0 indica la victoria del equipo visitante. Determinado por la comparación de puntos finales entre equipos.

---

2. Entidad: player_stats

Esta tabla registra el rendimiento individual pormenorizado de cada jugador por cada partido. Contiene 39 atributos que permiten un análisis profundo desde volumen de juego hasta eficiencia.

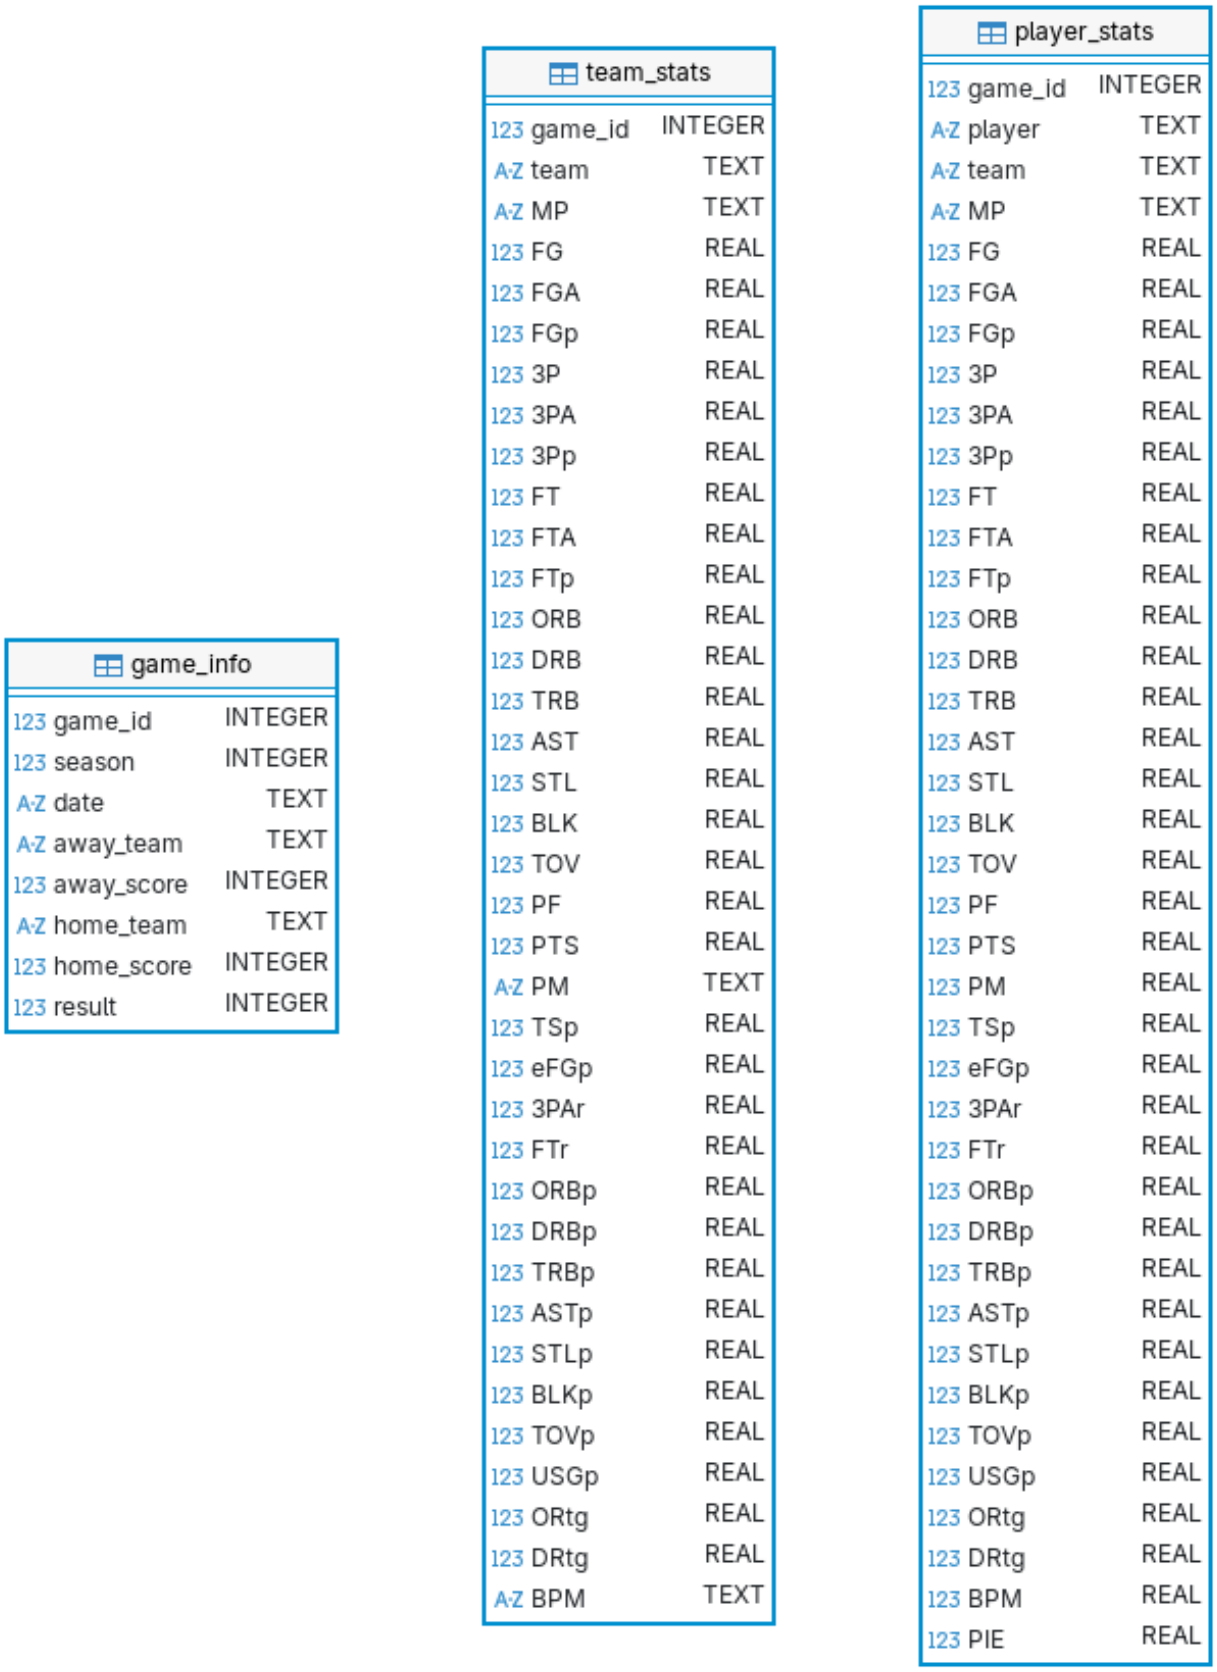

Figure 1: Diagrama NO Normalizada (0FN)

game_id: Identificador del partido, utilizado para vincular al jugador con un evento específico en game_info.

player: Nombre completo del jugador tal como aparece en el registro oficial.

team: Equipo específico al que pertenecía el jugador en el momento de disputar ese partido.

MP (Minutos Jugados): Tiempo total cronometrado que el jugador permaneció en pista durante el encuentro.

FG: Tiros de campo anotados. Incluye todos los lanzamientos de dos y tres puntos convertidos.

FGA: Tiros de campo intentados. Total de lanzamientos realizados, sin importar si fueron convertidos o errados.

3P: Tiros de tres puntos anotados. Lanzamientos convertidos desde detrás de la línea de tres puntos.

3PA: Tiros de tres puntos intentados. Total de lanzamientos realizados desde la larga distancia.

FT: Tiros libres anotados. Lanzamientos de un punto convertidos desde la línea de personal.

FTA: Tiros libres intentados. Total de lanzamientos realizados desde la línea de personal.

ORB: Rebotes ofensivos capturados. Balones recuperados por el jugador tras un fallo de su propio equipo.

DRB: Rebotes defensivos capturados. Balones recuperados por el jugador tras un fallo del equipo oponente.

TRB: Rebotes totales. La suma aritmética de los rebotes ofensivos (ORB) y defensivos (DRB).

AST: Asistencias realizadas. Pases que conducen directamente a una canasta anotada por un compañero.

STL: Robos de balón conseguidos. Acciones defensivas que quitan la posesión al oponente.

BLK: Tapones realizados. Desviación legal de un tiro del oponente que evita la canasta.

TOV: Pérdidas de balón cometidas. Veces que el jugador pierde la posesión antes de intentar un tiro o asistencia.

PF: Faltas personales cometidas. Infracciones al reglamento registradas por los árbitros contra el jugador.

Definición de Atributos Calculados y Métricas de Impacto

PTS (Puntos): Producción total de anotación sumando el valor de cada tiro convertido. Fórmula: $(3P \cdot 3) + (FG - 3P) \cdot 2 + FT$.

PM (Plus/Minus): Diferencial de puntos del equipo mientras el jugador estaba físicamente en la cancha. Mide el impacto neto del jugador en el marcador.

FGp (Porcentaje de Tiros de Campo): Relación entre tiros anotados e intentados. Fórmula: FG/FGA.

3Pp (Porcentaje de Triples): Eficiencia desde la línea de tres puntos. Fórmula: $3P/3PA$.

FTp (Porcentaje de Tiros Libres): Eficiencia desde la línea de tiros libres. Fórmula: FT/FTA.

TSp (True Shooting Percentage): Medida de eficiencia de tiro que combina puntos, tiros de campo intentados y tiros libres. Fórmula: $PTS/(2 \cdot (FGA + 0.44 \cdot FTA))$.

eFGp (Effective Field Goal Percentage): Porcentaje de tiro que ajusta el valor de los triples, otorgándoles un 50% más de peso. Fórmula: $(FG + 0.5 \cdot 3P)/FGA$.

3PAr (3-Point Attempt Rate): Proporción de lanzamientos que son intentos de tres puntos respecto al total de tiros de campo. Fórmula: $3PA/FGA$.

FTr (Free Throw Rate): Proporción de intentos de tiro libre generados por cada tiro de campo intentado. Fórmula: FTA/FGA.

ORBp (Offensive Rebound Percentage): Porcentaje estimado de rebotes ofensivos disponibles capturados por el jugador. Fórmula: $100 \cdot (ORB \cdot (Tm\ MP/5))/(MP \cdot (Tm\ ORB + Opp\ DRB))$.

DRBp (Defensive Rebound Percentage): Porcentaje estimado de rebotes defensivos disponibles capturados por el jugador. Fórmula: $100 \cdot (DRB \cdot (Tm\ MP/5))/(MP \cdot (Tm\ DRB + Opp\ ORB))$.

TRBp (Total Rebound Percentage): Porcentaje de todos los rebotes disponibles capturados por el jugador. Fórmula: $100 \cdot (TRB \cdot (Tm\ MP/5))/(MP \cdot (Tm\ TRB + Opp\ TRB))$.

ASTp (Assist Percentage): Estimación del porcentaje de canastas de sus compañeros que el jugador asistió mientras jugaba. Fórmula: $100 \cdot AST/(((MP/(Tm\ MP/5)) \cdot Tm\ FG) - FG)$.

STLp (Steal Percentage): Porcentaje de posesiones del oponente que terminan en robo por parte del jugador. Fórmula: $100 \cdot (STL \cdot (Tm\ MP/5))/(MP \cdot Opp\ Poss)$.

BLKp (Block Percentage): Porcentaje de tiros de dos puntos del oponente que son bloqueados por el jugador. Fórmula: $100 \cdot (BLK \cdot (Tm\ MP/5))/(MP \cdot (Opp\ FGA - Opp\ 3PA))$.

TOVp (Turnover Percentage): Estimación de las pérdidas de balón cometidas por cada 100 jugadas finalizadas. Fórmula: $100 \cdot TOV/(FGA + 0.44 \cdot FTA + TOV)$.

USGp (Usage Percentage): Porcentaje de las jugadas del equipo que el jugador finaliza mediante un tiro, tiro libre o pérdida. Fórmula: $100 \cdot ((FGA + 0.44 \cdot FTA + TOV) \cdot (Tm\ MP/5))/(MP \cdot (Tm\ FGA + 0.44 \cdot Tm\ FTA + Tm\ TOV))$.

ORtg (Offensive Rating): Estimación de los puntos producidos por el jugador por cada 100 posesiones individuales. Fórmula: $(Puntos\ Producidos/Posesiones\ Totales) \cdot 100$.

DRtg (Defensive Rating): Estimación de los puntos permitidos por el jugador por cada 100 posesiones defensivas. Fórmula: $(Puntos\ Permitidos/Posesiones\ Enfrentadas) \cdot 100$.

BPM (Box Plus/Minus): Estimación de los puntos por cada 100 posesiones que un jugador aporta sobre el promedio de la liga, calculada mediante regresión.

PIE (Player Impact Estimate): Métrica avanzada que mide el porcentaje de eventos estadísticos positivos que un jugador logra en un partido en relación con el total del encuentro.

$$PIE = \frac{(PTS + FGM + FTM - FGA - FTA + DREB + (OREB/2) + AST + STL + (BLK/2) - PF - TOV)}{\text{Denominador Global (G)}}$$

Denominador Global (G): Representa la suma de todos los eventos estadísticos positivos y negativos

realizados por ambos equipos (el equipo del jugador y su oponente) en el partido.

$$G = (PTS_{tot} + FGM_{tot} + FTM_{tot} - FGA_{tot} - FTA_{tot} + DREB_{tot} + \frac{OREB_{tot}}{2} + AST_{tot} + STL_{tot} + \frac{BLK_{tot}}{2} - PF_{tot} - TOV_{tot})$$

Significado de los Subíndices "tot" (Totales): El subíndice $_{tot}$ es fundamental para la precisión de la métrica. Indica que el valor no pertenece a un solo jugador o equipo, sino a la suma acumulada de las estadísticas de ambos equipos (Local y Visitante) que participan en el encuentro. Por ejemplo, PTS_{tot} es la suma de los puntos anotados por el equipo local y el equipo visitante combinados. Esto permite que el PIE sea un indicador de impacto relativo al contexto total del juego.

---

3. Entidad: team_stats

Esta tabla captura el rendimiento colectivo del equipo por partido. Incluye 37 atributos que reflejan la ejecución grupal sumada.

game_id: Identificador único del partido para vinculación relacional.

team: Nombre o abreviatura oficial del equipo analizado en el registro.

MP: Minutos totales jugados por el equipo (generalmente 240 minutos en un partido estándar).

FG: Tiros de campo totales anotados por todos los jugadores del equipo.

FGA: Tiros de campo totales intentados por el equipo.

3P: Tiros de tres puntos totales anotados por el equipo.

3PA: Tiros de tres puntos totales intentados por el equipo.

FT: Tiros libres totales anotados por el equipo.

FTA: Tiros libres totales intentados por el equipo.

ORB: Rebotes ofensivos totales capturados por el equipo.

DRB: Rebotes defensivos totales capturados por el equipo.

TRB: Cantidad total de rebotes (ofensivos y defensivos) del equipo.

AST: Asistencias totales repartidas por los jugadores del equipo.

STL: Robos de balón totales conseguidos por la defensa del equipo.

BLK: Tapones totales realizados por los defensores del equipo.

TOV: Pérdidas de balón totales cometidas por el equipo.

PF: Faltas personales totales acumuladas por el equipo.

PTS: Puntos totales anotados por el equipo en el partido.

TSp / eFGp / 3PAr / FTr: Ratios colectivos de eficiencia calculados bajo las mismas fórmulas de jugador pero aplicadas a los totales del equipo.

ASTp (Team Assist Percentage): Proporción de canastas de campo anotadas por el equipo que vinieron precedidas por una asistencia. Fórmula: $100 \cdot Equipo\ AST / Equipo\ FG$.

ORtg (Team Offensive Rating): Puntos totales que el equipo anota por cada 100 posesiones de balón.

DRtg (Team Defensive Rating): Puntos totales que el equipo permite a su oponente por cada 100 posesiones.

Modelo Normalizado (3FN)

Este informe detalla la evolución del dataset de boxscores de la NBA (2013-2023) desde una estructura plana hacia un esquema relacional en Tercera Forma Normal (3FN). Esta transición optimiza la integridad de los datos y elimina redundancias críticas presentes en el modelo original.

---

1. Justificación de la Normalización a 3FN

La estructura original contenía redundancias que ponían en riesgo la integridad de la base de datos. La normalización a 3FN se realizó por tres razones fundamentales:

Eliminación de Redundancia: Los nombres de jugadores y equipos ahora existen en un solo lugar. Si un jugador cambia su nombre legal, solo se actualiza una fila en la tabla Jugadores en lugar de miles en las tablas de estadísticas. Esto garantiza una única fuente de verdad.

Integridad Referencial: Mediante el uso de Claves Foráneas (Foreign Keys), aseguramos que no existan estadísticas para partidos, jugadores o equipos que no hayan sido previamente registrados en sus respectivas tablas maestras.

Eficiencia de Almacenamiento: Al sustituir cadenas de texto repetitivas por identificadores numéricos, se reduce drásticamente el peso de la base de datos y se aceleran las operaciones de búsqueda mediante la creación de índices.

---

2. Entidades Creadas

Equipos / Jugadores / Temporadas: Son tablas maestras que almacenan los nombres, abreviaturas y códigos únicos de identificación (IDs). Una vez registrados aquí, estos datos no se repiten en otras partes del sistema.

Partidos: Es la tabla central que vincula la fecha y la temporada con los IDs correspondientes a los equipos local y visitante. Define el evento de forma unívoca.

Est_Equipos / Est_Jugadores: Son las tablas de hechos. Almacenan únicamente las métricas base o "crudas" recolectadas en cada partido. Aquí se registran los conteos directos como tiros anotados, rebotes, asistencias, etc.

---

3. Atributos "Dejados Atrás" y Justificación Analítica

En este esquema normalizado, se han eliminado de las tablas físicas todos los atributos que son calculables. Esto incluye PTS, TSp, eFGp, ORtg, DRtg, PIE y Result, cuyas definiciones y fórmulas se detallaron extensamente en la Sección 1.

Justificación Técnica: En 3FN, no se deben almacenar bajo ningún concepto atributos que puedan ser derivados matemáticamente a partir de otros campos ya presentes. Almacenar los puntos (PTS) físicamente crea un riesgo de inconsistencia: si un analista actualiza manualmente los triples (3P) pero olvida actualizar los puntos totales (PTS), la base de datos contendría información contradictoria. Fórmula de puntos como ejemplo: $PTS = (3P \cdot 3) + (FG - 3P) \cdot 2 + FT$.

En el modelo normalizado, estos valores se calculan en tiempo real a través de Vistas SQL (Views) o en la capa de visualización de datos. Esto garantiza que cualquier cambio en las estadísticas base se refleje inmediatamente y de forma exacta en todas las métricas avanzadas y resultados.

---

4. Relaciones del Modelo

El modelo se basa en una **estructura de estrella** donde las estadísticas (tablas de hechos) orbitan alrededor de los catálogos (dimensiones) y el evento principal (el partido). A continuación, se detallan las dependencias y cardinalidades:

- **Temporadas a Partidos ($1 : N$):** Una temporada contiene múltiples partidos, pero un partido solo pertenece a una temporada específica.
- **Equipos a Partidos ($1 : N$):** Un equipo participa en muchos partidos a lo largo del tiempo. La tabla **Partidos** mantiene dos relaciones fundamentales con la tabla **Equipos**: una para el rol de `id_local` y otra para el `id_visitante`.
- **Partidos a Estadísticas ($1 : N$):** Un partido genera exactamente dos registros en la entidad `Est_Equipos` (equipo local y visitante) y múltiples registros en `Est_Jugadores` (un registro por cada jugador que haya pisado la pista durante el encuentro).
- **Jugadores a Est_Jugadores ($1 : N$):** Un jugador genera un nuevo registro de estadísticas por cada partido disputado, permitiendo el seguimiento de su rendimiento histórico.
- **Equipos a Est_Jugadores ($1 : N$):** Esta relación es crucial para identificar en qué equipo jugaba un atleta en un partido específico. Esto permite rastrear con precisión los **traspasos** y movimientos de mercado a lo largo de la temporada.

---

5. Diccionario de Atributos Base (Mantenidos)

Estos son los campos fundamentales que se conservan físicamente en las tablas de estadísticas para permitir todos los cálculos analíticos:

MP: Minutos totales jugados por el jugador o equipo. Tiempo total cronometrado en pista.

FG: Field Goals Made. Tiros de campo totales convertidos (incluye dobles y triples).

FGA: Field Goals Attempted. Total de tiros de campo intentados.

3P: 3-Point Made. Lanzamientos de larga distancia convertidos.

3PA: 3-Point Attempted. Lanzamientos de larga distancia intentados.

FT: Free Throws Made. Lanzamientos desde la línea de personal convertidos.

FTA: Free Throws Attempted. Lanzamientos desde la línea de personal intentados.

ORB: Offensive Rebounds. Rebotes capturados en ataque tras fallo del propio equipo.

DRB: Defensive Rebounds. Rebotes capturados en defensa tras fallo del rival.

AST: Assists. Pases de canasta realizados que resultan en anotación inmediata.

STL: Steals. Balones recuperados defensivamente quitando la posesión al oponente.

BLK: Blocks. Lanzamientos del rival desviados legalmente evitando la canasta.

TOV: Turnovers. Balones perdidos por el jugador o equipo antes de un lanzamiento.

PF: Personal Fouls. Faltas personales señaladas por el arbitraje durante el juego.

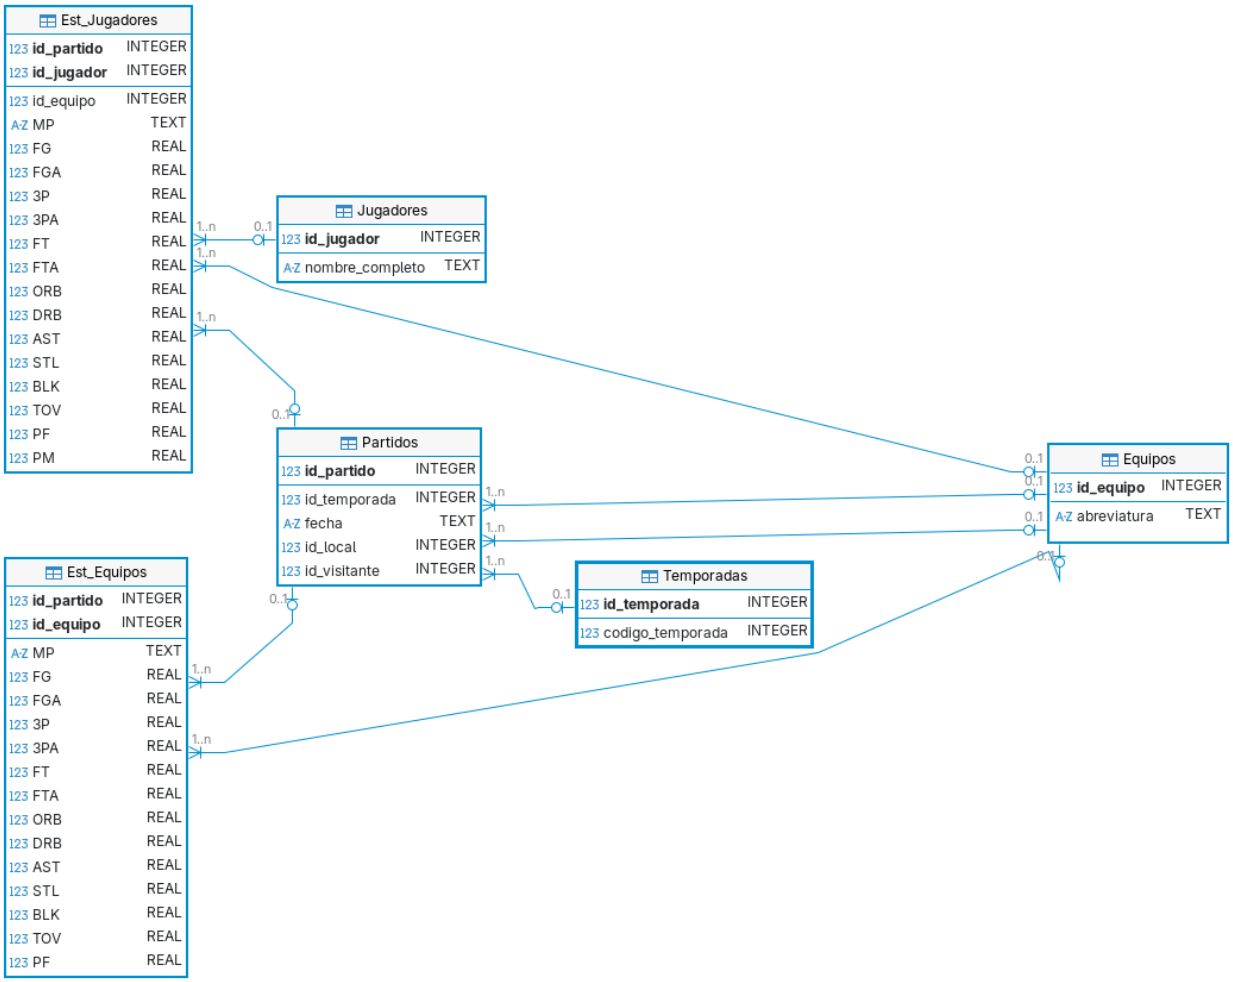

Figure 2: Diagrama de la Base de Datos Normalizada (3FN)

Referencias

Para la elaboración de este informe técnico y la definición de las métricas de eficiencia, se han consultado las siguientes fuentes oficiales y repositorios de datos:

Fuente Principal del Database

- **DiPerna, L. (2023). NBA Boxscore Dataset (2013-2023):** Kaggle Dataset - NBA Boxscores
  Nota: Esta es la fuente primaria del esquema SQL utilizado en este reporte, proporcionando la estructura de las tablas `game_info`, `player_stats` y `team_stats`.

Definiciones y Glosario Estadístico

- **Basketball Reference:** About the Four Factors
  (Referencia estándar para el cálculo de posesiones y factores de eficiencia).
- **SportsVisio:** Basketball Stats Explained
  (Guía detallada sobre la interpretación de estadísticas modernas).
- **Breakthrough Basketball:** Statistical Definitions
  (Glosario de términos básicos y avanzados de rendimiento).

Métricas Avanzadas y Contexto

- **Wikipedia:** Player Efficiency Rating (PER)
  (Fundamentos teóricos del impacto individual desarrollado por John Hollinger).
- **Jóźwiak, S. (2024):** NBA Traditional Stats Dataset
  (Referencia comparativa para validación de estadísticas tradicionales).